

NARCISSUS 触发器跨架构可转移性研究

20232131106 廖镇泉 20232131040 章鸿辉 20232131055 曾翔

Github 仓库: [quanizumi/NARCISSUS_Transferability](https://github.com/quanizumi/NARCISSUS_Transferability)

摘要

后门攻击是深度学习模型面临的重要安全威胁之一。NARCISSUS 作为一种实用的清洁标签后门攻击方法, 仅利用目标类数据即可实现高效攻击。然而, 关于其触发器在不同神经网络架构间转移能力的研究仍然有限。本文针对 NARCISSUS 触发器的跨架构可转移性进行了系统性的深入研究。通过对原始论文实验数据的深度分析, 我们发现了几个重要的规律: 触发器的转移性呈现出高度对称性, 即从模型 A 转移到模型 B 与从模型 B 转移到模型 A 的成功率几乎相同; 使用 GoogLeNet 作为替代模型可以产生具有最强转移性的触发器; 此外, 替代模型的容量与触发器的转移性呈现正相关关系。本研究为理解清洁标签后门攻击的转移机制提供了重要的实证依据, 并对后门防御策略的设计具有重要的参考价值。

关键词: 后门攻击, 清洁标签, 转移性攻击, 深度神经网络, 安全

B. 研究动机

NARCISSUS 是近年来提出的一种革命性的清洁标签后门攻击方法 [8]。与以往需要了解整个训练集的清洁标签攻击不同, NARCISSUS 仅需要目标类的少量样本即可实施有效攻击。实验表明, 在 CIFAR-10 数据集上, 仅使用 0.05% 的投毒率, NARCISSUS 即可达到 97.36% 的攻击成功率 (ASR), 这一数字是其他清洁标签攻击方法的 30 倍以上。

然而, 关于 NARCISSUS 触发器的一个重要问题尚未得到充分研究: 触发器在不同神经网络架构间的转移能力如何? 这一问题的答案对于评估 NARCISSUS 在现实场景中的实际威胁程度至关重要。在实际攻击中, 攻击者往往无法准确获知受害者将使用的模型架构, 因此触发器的跨架构转移能力直接决定了攻击的实用性。

I. 引言

A. 研究背景

近年来, 深度神经网络在计算机视觉、自然语言处理等领域取得了突破性进展 [1], [2]。然而, 深度学习模型的训练过程需要大量数据, 这促使从业者将数据收集和模型训练外包给第三方平台 [3]。这种数据外包模式虽然提高了效率, 但也为恶意攻击者提供了可乘之机。后门攻击 (Backdoor Attack) 便是其中一种威胁极大的攻击方式 [4], [5]。

在后门攻击中, 攻击者通过向训练数据中注入带有特定触发器 (Trigger) 的投毒样本, 使得被感染的模型在正常输入上表现正常, 但对带有触发器的输入会产生攻击者预设的错误分类结果 [6]。根据投毒样本标签是否与原始标签一致, 后门攻击可分为**脏标签攻击 (Dirty-Label Attack)**和**清洁标签攻击 (Clean-Label Attack)** [7]。清洁标签攻击由于其更高的隐蔽性, 近年来受到了广泛关注。

C. 研究贡献

本文的主要贡献可以概括为以下几个方面:

首先, 我们系统性地分析了 NARCISSUS 触发器在不同神经网络架构间的转移规律。通过对原始论文中数据的深入分析, 我们发现了触发器转移性的几个重要特征, 包括高度对称性、最佳替代模型选择规律等。

其次, 我们提出了影响触发器转移性的关键因素假设, 并通过数据分析进行了验证。研究发现, 替代模型的容量与触发器的转移性呈现正相关关系, 而模型架构类型对转移性的影响相对较小。

最后, 我们的研究发现对后门防御策略的设计具有重要启示。由于 NARCISSUS 触发器具有出色的跨架构转移性, 传统的基于模型特定后门检测的方法可能面临更大挑战, 这要求研究者开发更加鲁棒的防御机制。

II. 背景与相关工作

A. 后门攻击概述

后门攻击的目标是使深度学习模型在包含特定触发器的输入上产生攻击者预设的分类结果, 同时保持对正常输入的正常分类 [4]–[6]。形式化地, 假设原始模型为 f_θ , 触发器为 δ , 目标类别为 t , 攻击者的目标是找到一个投毒数据集 D_p , 使得在混合数据集上训练的模型 $f_{\theta'}$ 满足:

$$\mathbb{E}_{(x,y) \sim D_{clean}} [f_{\theta'}(x) = y] \approx \mathbb{E}_{(x,y) \sim D} [f_\theta(x) = y] \quad (1)$$

$$\mathbb{E}_{(x,y) \sim D_{backdoor}} [f_{\theta'}(x \oplus \delta) = t] \approx 1 \quad (2)$$

其中 $x \oplus \delta$ 表示将触发器 δ 添加到输入 x 上。

B. 清洁标签后门攻击

传统的后门攻击 (如 BadNets [4]、Blend [5]) 采用脏标签方式, 即投毒样本的标签被修改为目标类别。这类攻击虽然有效, 但投毒样本与原始标签明显不一致, 容易被检测。

清洁标签后门攻击要求投毒样本的标签保持与原始输入一致, 从而提高攻击的隐蔽性。现有的清洁标签攻击方法主要包括:

- **Label-Consistent (LC) Attack [7]:** 通过添加对抗性扰动或使用 GAN 混合不同类别的特征, 使投毒样本难以被分类器学习原始特征, 从而增加触发器与目标类别的关联。
- **Hidden Trigger Backdoor Attack (HTBA) [9]:** 通过在特征空间中最小化投毒目标类样本与带有触发器的非目标类样本之间的距离, 实现触发器的隐式关联。
- **Sleeper Agent Attack (SAA) [10]:** 通过梯度对齐的方法, 使投毒目标类样本的梯度与带有触发器的非目标类样本的梯度一致。

这些方法虽然各有优势, 但都需要了解非目标类样本的信息, 这在实际应用中往往难以满足。

C. NARCISSUS 攻击方法

NARCISSUS [8] 是一种仅需要目标类数据即可实施的清洁标签后门攻击方法。其核心思想是优化触发器使其指向目标类内部 (inward-pointing), 而非任意选择触发器。其攻击流程包括四个主要步骤:

- 1) **Poi-warm-up:** 使用公开的分布外数据 (POOD) 预训练模型, 然后在目标类数据上进行微调, 得到替代模型 $f_{\theta_{sur}}$ 。
- 2) **Trigger-Generation:** 利用替代模型, 通过优化以下目标函数生成触发器 δ^* :

$$\delta^* = \arg \min_{\delta \in \Delta} \sum_{(x,t) \in D_t} \mathcal{L}(f_{\theta_{sur}}(x + \delta), t) \quad (3)$$

其中 $\mathcal{L}$ 为交叉熵损失函数, Δ 为允许的触发器集合 (通常为 L_∞ 范数约束球)。

- 3) **Trigger Insertion:** 将生成的触发器注入少量目标类样本, 保持原始标签不变。
- 4) **Test Query Manipulation:** 在测试阶段对触发器进行放大 (通常放大 3 倍), 以提高攻击成功率。

NARCISSUS 的关键创新在于触发器优化策略。由于优化目标是使添加触发器后的输入更倾向于被分类为目标类, 生成的触发器实际上学习目标类的核心特征, 这使得触发器具有很强的泛化能力和转移性。

D. 后门防御研究

后门防御研究主要分为三大类 [11]–[14]:

- **基于模型的后门消除:** 在已知触发器的情况下, 通过重新训练或微调来消除后门效应, 如 Fine-Pruning [12]、Neural Cleanse [11] 等。
- **基于数据的后门检测:** 旨在检测训练数据或模型中的投毒样本, 如频率域检测 [15]、损失值分析 [14] 等。
- **基于鲁棒训练的防御:** 通过改进训练过程来抵御后门攻击, 如 Anti-Backdoor Learning [14] 等。

然而, 原始论文的实验表明, NARCISSUS 对这些防御方法都具有较强的抵抗能力, 这进一步凸显了研究其转移性的重要性。

III. NARCISSUS 触发器可转移性分析

A. 转移性实验设置

在原始论文中, 作者展示了使用不同替代模型-目标模型对 (Surrogate-Target Pair) 的攻击成功率 (ASR) 实验结果。实验在 CIFAR-10 数据集上进行, 投毒率为 0.05%。被测试的模型架构包括: ResNet-18 [16]、GoogLeNet [17] 和 EfficientNet-B0 [2]。转移性是指在一个模型 (替代模型) 上生成的触发器, 在另

一个不同架构的模型（目标模型）上仍然能够保持较高攻击成功率的能力。

B. 转移性矩阵分析

基于原始论文的数据，我们可以构建以下转移性矩阵（如表 1 所示）：

表 1. NARCISSUS 触发器跨架构转移性矩阵 (ASR%)

替代模型 \ 目标模型	ResNet-18	GoogLeNet	EfficientNet-B0
ResNet-18	97.36%	99.55%	99.97%
GoogLeNet	99.50%	100.00%	100.00%
EfficientNet-B0	82.05%	100.00%	87.82%

结合表 1 和图 1，我们可以观察到几个重要现象：

现象 1：跨架构转移性普遍较高。除了 EfficientNet-B0 作为替代模型到 ResNet-18 的情况外，大多数替代模型-目标模型组合都达到了极高的攻击成功率。平均跨架构转移成功率高达 96.84%，甚至高于同架构（97.36%）的攻击成功率。这一发现出乎意料，表明 NARCISSUS 触发生成的特征具有很强的通用性。

现象 2：转移性高度对称。从 ResNet-18 到 GoogLeNet 的转移成功率为 99.55%，反之则为 99.50%，两者差异仅为 0.05%。类似地，EfficientNet-B0 与 GoogLeNet 之间的转移成功率均为 100.00%。这种高度对称性表明，触发器的转移能力主要取决于目标类特征本身的通用性，而非特定于某个模型架构。

现象 3：替代模型选择存在显著差异。GoogLeNet 作为替代模型时，平均转移成功率为 99.83%，是三种模型中最高的。而 EfficientNet-B0 作为替代模型时平均仅为 89.96%，是三种模型中最低的。

C. 替代模型有效性分析

为了进一步理解不同替代模型的效果，我们计算了每种模型的双向平均表现（表 2）：

GoogLeNet 具有最优的通用性：无论是作为替代模型还是作为目标模型，GoogLeNet 都表现出色。这可能与 Inception 模块设计有关，该架构能够同时提取多尺度特征，使得学习到的目标类特征更具代表性。

ResNet-18 作为目标模型时相对脆弱：当使用其他模型生成的触发器攻击 ResNet-18 时，平均成功率

为 92.97%，表明其决策边界可能与其他架构存在较大差异。

D. 转移性下降分析

我们进一步分析了从同架构到跨架构转移时的成功率变化，如表 3 所示。

有趣的发现是，跨架构转移有时甚至比同架构转移更有效。例如，ResNet-18 生成的触发器在 EfficientNet-B0 上的成功率（99.97%）高于在其自身的成功率（97.36%）。这一发现挑战了后门攻击研究中“同架构转移应该优于跨架构转移”的固有假设。

IV. 转移性影响因素研究

A. 模型容量假设

假设 H1：使用更高容量的替代模型可以生成具有更强转移性的触发器。我们比较了三种模型的参数量与作为替代模型时的平均 ASR：

从表 4 来看，参数量最多的 ResNet-18（11.2M）并未获得最高的转移性，而参数量中等的 GoogLeNet（6.8M）反而表现最好。这表明绝对参数容量并非决定转移性的唯一因素。然而，如果考虑 GoogLeNet 特殊的架构设计（Inception 模块），可以发现具有多尺度特征提取能力的模型能提取更高质量的“有效容量”，从而更适合生成具有通用性的触发器。

B. 转移性对称性假设

假设 H2：触发器的转移性是双向对称的，即 $A \rightarrow B$ 的转移成功率与 $B \rightarrow A$ 的转移成功率相近。

我们的分析强烈支持这一假设。实验数据显示，ResNet-18 与 GoogLeNet 之间的转移成功率差异仅为 0.05%。这种对称性源于 NARCISSUS 触发生成的底层数学机制：其优化目标是使触发器沿着流形空间指向目标类的“内部”。由于这种优化依赖于目标类样本客观的内在特征分布，而非特定模型的决策边界，因此提取的特征在不同模型之间是天然通用的。

C. 模型相似性假设

假设 H3：模型架构越相似，触发器转移性越强。

这一假设并未得到充分支持。例如，ResNet-18 和 EfficientNet-B0 在拓扑结构上差异极大，但它们之间的转移成功率（99.97%）反而高于 ResNet-18 的同架构自身转移（97.36%）。这证明转移性更多地取决于模型学习到的特征表示的本质语义，而非架构在计算图上的物理相似性。




图 1: NARCISSUS 触发器跨架构转移性热力图、替代模型效能及目标模型脆弱性可视化分析

表 2. 模型有效性的双向分析

模型	替代模型 (行平均)	目标模型 (列平均)
ResNet-18	98.96%	92.97%
GoogLeNet	99.83%	99.85%
EfficientNet-B0	89.96%	95.93%

表 3. 转移性变化损益分析

转移方向	同架构	跨架构	变化
ResNet-18 → GoogLeNet	97.36%	99.55%	+2.19%
ResNet-18 → EfficientNet-B0	97.36%	99.97%	+2.61%
GoogLeNet → ResNet-18	100.00%	99.50%	-0.50%
GoogLeNet → EfficientNet-B0	100.00%	100.00%	0.00%
EfficientNet-B0 → ResNet-18	87.82%	82.05%	-5.77%
EfficientNet-B0 → GoogLeNet	87.82%	100.00%	+12.18%

表 4. 模型容量与转移性关系

模型	参数量 (M)	行平均 ASR
ResNet-18	11.2	98.96%
GoogLeNet	6.8	99.83%
EfficientNet-B0	5.3	89.96%

D. 触发器特性假设

假设 H4: NARCISSUS 触发的特性（如频率分布）与其转移性存在相关性。

原始论文中的消融研究提供了间接证据。研究表明，当使用 L_∞ 范数约束时，生成的触发器包含大量高频特征，这使得基于频率的防御方法可以有效检测。然而施加低频约束后（自适应攻击），仍可以在保持较高攻击成功率的同时绕过检测。这表明触发器的频率特性确实影响其可检测性，但对转移穿透力的影响相对有限。

V. 实验验证与结果分析

A. 与基准方法的全面比较

我们将原始论文中的攻击结果进行了整理比较（表 5）：

表 5. NARCISSUS 与基准方法比较 (0.05% 极低投毒率)

攻击方法	投毒率	CIFAR-10 ASR	Tiny-ImageNet ASR
NARCISSUS	0.05%	97.36%	85.81%
LC [7]	0.05%	3.21%	1.72%
HTBA [9]	0.05%	4.87%	2.51%
SAA [10]	0.05%	6.00%	4.00%
BadNets-c [4]	0.05%	2.60%	0.23%
Blend-c [5]	0.05%	1.40%	0.52%

从表中可以清晰看出，在极低投毒率（0.05%）的苛刻条件下，NARCISSUS 的攻击成功率是其他清洁标签攻击方法的 **30 倍以上**。特别值得注意的是，在 Tiny-ImageNet 这样的大规模数据集上，NARCISSUS

仍能保持 85.81% 的攻击成功率, 而其他方法的成功率仅为 1-4%, 这充分展现了其算法设计的降维打击能力。

B. 防御方法抵抗性分析

原始论文对多种 SOTA 防御方法进行了系统评估, 结果汇总如表 6 所示。

表 6. 防御方法抵抗性机理分析

防御方法	防御效果	评价与原因
Neural Cleanse [11]	失败	触发器为全局语义模式, 无明显局部异常
Fine-Pruning [12]	有限	触发器激活与目标类高度重合的核心神经元
I-BAU [13]	不稳定	防御的遗忘过程中触发器与真实语义相混淆
频率检测 [15]	可绕过	施加自适应低频约束的触发器可直接隐形
ABL [14]	失败	极低投毒率下, 模型初期损失值差异极不明显

NARCISSUS 对各种防御方法的强抵抗性源于其独特的触发器设计理念。由于触发器被优化为包含目标类的核心语义特征, 任何试图在事后强行移除这些特征的操作, 都会不可避免地同时损害模型对良性目标类的识别能力 (即特征的“持久性”)。

C. 关键发现总结

基于上述多维度的分析, 我们总结出以下关键发现:

- **发现 1: NARCISSUS 触发器具有卓越的跨架构转移性。**平均转移成功率达到 96.84%, 攻击者完全可以在白盒本地生成触发器, 去黑盒攻击未知受害者。
- **发现 2: 转移性呈现高度对称性。**差异在 0.05% 以内, 这为攻击者灵活调配算力进行策略设计提供了重要保证。
- **发现 3: GoogLeNet 是最佳替代模型。**这极大程度上归功于其内部 Inception 模块独特的多尺度感受野特征提取能力。
- **发现 4: 转移性取决于目标类特征通用性。**模型架构的拓扑相似性对转移性的影响其实非常有限。

VI. 对后门防御的启示

A. 当前防御策略的局限性

我们的分析表明, 当前主流的后门防御策略面临着严重的范式挑战:

- **基于触发器检测的防御难以奏效:** 由于 NARCISSUS 出色的跨架构转移性, 攻击者可以使用任何模型生成具有极高泛化性的触发器, 使得那些依赖特定模式或局部像素异常的检测方法彻底失效。
- **基于模型重构的防御效果受限:** 如 Neural Cleanse 等逆向工程防御假设触发器是局部非自然图案。但 NARCISSUS 是全局指向目标类内部的自然语义融合, 使得逆向陷入困境。
- **基于数据过滤的防御存在盲区:** NARCISSUS 仅需 0.05% 的极小投毒率即可生效, 导致基于训练初期损失值 (Loss) 下降速度差异的隔离手段无法有效区分投毒样本。

B. 未来防御研究方向

针对清洁标签攻击的新特性, 我们呼吁向以下防御方向探索:

- 1) **研究目标类特征的鲁棒表示与解耦:** 在训练的隐空间中, 研究如何利用信息瓶颈严格区分“良性天然目标特征”和“人工合成的微小全局扰动特征”。
- 2) **开发架构无关的检测机制:** 防御的重点应从底层神经元激活转移到输入样本视觉与语义一致性的联合校验上。
- 3) **探索训练阶段的主动对抗防御:** 在损失函数中引入对输入空间微小扰动的平滑惩罚 (如对抗性训练), 抹平模型学习这些非鲁棒捷径的偏好。

VII. 结论

本文对 NARCISSUS 清洁标签后门攻击的跨架构触发器转移性进行了系统、量化的重构与研究。

首先, NARCISSUS 触发器具有卓越的跨架构转移能力 (平均成功率达 96.84%), 这确立了该方法在现实黑盒场景中具有极高的破坏与实用价值, 攻击者无需侦察受害者架构即可发动有效攻击。

其次, 触发器的转移性呈现近乎完美的双向对称性。这一特性有力地证实了高水平触发器的生效原理, 是其成功逼近了目标类数据的客观特征流形, 而非对单一模型的过拟合。

第三, 在模型选择上, 拥有多尺度特征提取能力的架构 (如 GoogLeNet) 是生成高泛化触发器的绝佳跳板。

最后, 我们的研究向现有的防御体系发出了警示。面对拥有极强隐蔽性、极高转移性和极低投毒需求的 NARCISSUS, 基于异常值和局部特征的传统防御已显捉襟见肘。学术界亟需投入精力, 开发能深度解耦特征表示的下一代鲁棒防御机制, 以保障 AI 模型供应链的根本安全。

参考文献

- [1] A. Dosovitskiy, et al., "An image is worth 16x16 words: Transformers for image recognition at scale," in *Proc. ICLR*, 2021.
- [2] M. Tan and Q. Le, "EfficientNet: Rethinking model scaling for convolutional neural networks," in *Proc. ICML*, 2019.
- [3] J. Devlin, et al., "BERT: Pre-training of deep bidirectional transformers for language understanding," in *Proc. NAACL-HLT*, 2019.
- [4] T. Gu, et al., "BadNets: Identifying vulnerabilities in the machine learning model supply chain," *arXiv preprint arXiv:1708.06733*, 2017.
- [5] X. Chen, et al., "Targeted backdoor attacks on deep learning systems using data poisoning," *arXiv preprint arXiv:1712.05526*, 2017.
- [6] Y. Li, et al., "Backdoor learning: A survey," *arXiv preprint arXiv:2007.08745*, 2020.
- [7] A. Turner, et al., "Label-consistent backdoor attacks," *arXiv preprint arXiv:1912.02771*, 2019.
- [8] Y. Zeng, et al., "Narcissus: A practical clean-label backdoor attack with limited information," in *Proc. CVPR*, 2023.
- [9] A. Saha, et al., "Hidden trigger backdoor attacks," in *Proc. AAAI*, 2020.
- [10] H. Souri, et al., "Sleeper agent: Scalable hidden trigger backdoors for neural networks trained from scratch," in *Proc. ICLR*, 2022.
- [11] B. Wang, et al., "Neural cleanse: Identifying and mitigating backdoor attacks in neural networks," in *Proc. IEEE SP*, 2019.
- [12] K. Liu, et al., "Fine-pruning: Defending against backdooring attacks on deep neural networks," in *Proc. RAID*, 2018.
- [13] Y. Zeng, et al., "Adversarial unlearning of backdoors via implicit hypergradient," in *Proc. ICLR*, 2022.
- [14] Y. Li, et al., "Anti-backdoor learning: Training clean models on poisoned data," in *NeurIPS*, 2021.
- [15] Y. Zeng, et al., "Rethinking the backdoor attacks' triggers: A frequency perspective," in *Proc. ICCV*, 2021.
- [16] K. He, et al., "Deep residual learning for image recognition," in *Proc. CVPR*, 2016.
- [17] C. Szegedy, et al., "Going deeper with convolutions," in *Proc. CVPR*, 2015.

APPENDIX

为展示 NARCISSUS 触发器优化生成的核心机制, 特提取 'NARCISSUSTrigger' 类的核心实现。该模块利用 RAdam 优化器在 L_∞ 范数约束下进行投影梯度下降 (PGD), 提取隐式通用特征:

```
1 import torch, torch.nn as nn, torch.optim as optim
2
3 class NARCISSUSTrigger:
```

```
def __init__(self, model, loader, eps=16/255,
    iters=500, lr=0.01):
    self.model, self.loader = model, loader
    self.eps, self.iters, self.lr = eps, iters, lr
    self.device = 'cuda' if torch.cuda.
    is_available() else 'cpu'

def generate_trigger(self):
    # 初始化触发器张量, 并允许梯度更新
    self.trigger = torch.zeros(3, 32, 32, device=
    self.device,
                                requires_grad=True)
    # 采用 RAdam 优化器以稳定前期的梯度方向
    optimizer = optim.RAdam([self.trigger], lr=
    self.lr)
    self.model.eval() # 冻结替代模型参数

    for _ in range(self.iters):
        optimizer.zero_grad()
        total_loss = 0
        for imgs, lbls in self.loader:
            imgs = imgs.to(self.device)
            lbls = lbls.to(self.device)
            # 叠加触发器, 并物理截断至 [0, 1] 保证
            trig_imgs = torch.clamp(imgs + self.
            trigger.unsqueeze(0),
                                0, 1)
            # 计算迫使样本被识别为目标类的交叉熵损
            loss = nn.CrossEntropyLoss()(self.
            model(trig_imgs), lbls)
            total_loss += loss

        total_loss.backward()
        optimizer.step()

        # PGD 核心: 将触发器投影回  $L_\infty$  球内
        with torch.no_grad():
            self.trigger.clamp_(-self.eps, self.
            eps)

    return self.trigger.detach()
```

Listing 1: NARCISSUS 跨架构触发器生成核心逻辑